

Programmation dynamique

Problème de l'alignement de séquences

Dans le contexte de la bio-informatique, un problème algorithmique essentiel est celui de *l'alignement de séquences*, typiquement pour comparer des séquences d'ADN. On peut le formaliser en ces termes : étant données deux chaînes de caractères, il s'agit de mettre en correspondance « le plus possible » les caractères de la première chaîne avec ceux de la seconde, en conservant l'ordre des caractères mais en s'autorisant à insérer des trous dans l'une ou l'autre chaîne. Si on considère par exemple les chaînes **GENOME** et **ENORME**, on peut aligner leurs caractères de la façon suivante, le caractère - étant utilisé pour désigner un trou :

```
G E N O - M E
- E N O R M E
```

Il existe de nombreuses autres façons d'aligner ces deux chaînes. En voici une autre :

```
G - - E N O M E
- E N O R - M E
```

La seule contrainte est que l'on doit utiliser tous les caractères de chaque chaîne, dans l'ordre, et que l'on n'aligne jamais deux trous (c'est-à-dire deux caractères -).

Parmi tous les alignements possibles, on cherche celui qui donne le score maximal.

Le score est ainsi calculé :

- l'alignement de deux caractères identiques donne 1 point ;
- en revanche, l'alignement de deux caractères différents, ce qui inclut l'alignement avec le caractère -, enlève un point.

Ainsi, le premier alignement proposé ci-dessus donne le score 3 : 5 caractères correctement alignés et 2 mauvais alignements. Pour le deuxième alignement, le score est - 4 : 2 caractères correctement alignés et 6 mauvais alignements.

A noter que les deux chaînes n'ont pas forcément la même longueur.

Ainsi, l'alignement

```
A S T U C I E U X
- S T U D I E U X
```

a le score 5.

Reprenons l'exemple des mots GENOME et ENORME et voyons ce qu'il en est de leur dernier caractère.

Ici, il s'agit du caractère E dans les deux cas. Il y a trois cas de figure :

- soit ces deux E sont alignés, on marque 1 point et on doit aligner les séquences GENOM et ENORM ;
- soit le E final de GENOM est aligné avec - : on perd 1 point et on doit aligner les séquences GENOM et ENORME ;
- soit le E final de ENORME est aligné avec - : on perd 1 point et on doit aligner les séquences GENOME et ENORM.

Comme il n'y a pas d'autre cas possible, le score maximal sera le maximum des trois scores obtenus.

Cas général : (plsch désignera l'abréviation de *plus longue sous-chaine*)

Soient $x_1x_2x_3 \dots x_n$ une séquence de n caractères et $y_1y_2 \dots y_p$ une autre séquence de p caractères.

Il y a également trois cas de figure :

- Alignement du caractère x_n avec - :
on perd 1 point et on doit aligner les séquences $x_1x_2x_3 \dots x_{n-1}$ et $y_1y_2 \dots y_p$, soit un score de $-1 + plsch(x_1x_2x_3 \dots x_{n-1}, y_1y_2 \dots y_p)$.
- Alignement du caractère y_p avec - :
on perd 1 point et on doit aligner les séquences $x_1x_2x_3 \dots x_n$ et $y_1y_2 \dots y_{p-1}$, soit un score de $-1 + plsch(x_1x_2x_3 \dots x_n, y_1y_2 \dots y_{p-1})$.
- Alignement des deux derniers caractères x_n et y_p :
 - Si $x_n = y_p$: on marque 1 point et on doit aligner les séquences $x_1x_2x_3 \dots x_{n-1}$ et $y_1y_2 \dots y_{p-1}$, soit un score de $1 + plsch(x_1x_2x_3 \dots x_{n-1}, y_1y_2 \dots y_{p-1})$;
 - Si $x_n \neq y_p$: on perd 1 point et on doit aussi aligner les séquences $x_1x_2x_3 \dots x_{n-1}$ et $y_1y_2 \dots y_{p-1}$, soit un score de $-1 + plsch(x_1x_2x_3 \dots x_{n-1}, y_1y_2 \dots y_{p-1})$.

Pour résoudre ce problème grâce à la programmation dynamique, on va utiliser un tableau à deux dimensions, nommé **sc**, dans lequel on va stocker, pour chaque paire de séquences, le score maximal.

Plus précisément, pour deux entiers i et j , on va stocker dans la case (i, j) le score maximal de l'alignement des i premiers caractères de la première séquence et des j premiers caractères de la deuxième séquence.

Pour commencer, le tableau **sc** est un tableau contenant uniquement des 0.

On peut ensuite affecter les valeurs $sc[0][j]$, c'est-à-dire la première ligne, et $sc[i][0]$, c'est-à-dire la première colonne.

Dans les deux cas, il s'agit de l'alignement avec un mot vide pour lequel la réponse est facile à calculer : il faut supprimer tous les caractères, ce qui produit un score égal à l'opposé de la longueur du mot considéré. Par exemple,

C E R F
- - - -

L'alignement de CERF avec une chaîne vide produit un score de -4 , soit l'opposé de la longueur du mot CERF.

On peut ensuite remplir le reste du tableau avec une double boucle.

Tableau sc							
$i \backslash j$		$j = 0$	$j = 1$	$j = 2$	$j = 3$	$j = \dots$	$j = p$
		" "	y_1	y_1y_2	$y_1y_2y_3$	...	$y_1y_2y_3 \dots y_p$
$i = 0$	" "	0	-1	-2	-3	...	-p
$i = 1$	x_1	-1		3	1		
$i = 2$	x_1x_2	-2		2	*		
$i = \dots$	...	...					
$i = n$	$x_1x_2 \dots x_n$	-n					

Pour calculer (*), on a besoin des cases 1, 2 et 3.

Exemple de remplissage : alignement de x_1x_2 avec $y_1y_2y_3$.

1	Alignement x_2 avec - ... x_2 ... - Il reste à déterminer la <i>plsch</i> entre x_1 et $y_1y_2y_3$	2	Alignement y_3 avec - ... - ... y_3 Il reste à déterminer la <i>plsch</i> entre x_1x_2 et y_1y_2	3	Alignement x_2 avec y_3 ... x_2 ... y_3 Il reste à déterminer la <i>plsch</i> entre x_1x_2 et y_1y_2
---	---	---	---	---	---

Travail à faire :

- Déterminer deux sous-chaînes communes aux séquences d'ADN suivantes et calculer leur score :
AGATGC et AGTATCT
- Compléter le fichier *alignement-sequence.py* (disponible sur l'ENT) pour que la fonction `aligne` renvoie le résultat souhaité (score du meilleur alignement entre deux séquences).